

Matematyczne podstawy sieci neuronowych

Piotr Dyszewski

2026-06-08

Spis treści

Słowo wstępne	3
1 Wstęp	4
2 Supervised Learning	5
3 Model neuronu i funkcja aktywacji	6
4 Płytkie uczenie	7
5 Stochastic Gradient Descent	8
6 Training	9
7 Głębokie sieci neuronowe	10
8 Initialization	11
9 Convolutional Neural Networks	12
10 Automatic Differentiation and Backpropagation	13
11 Adaptive Learning Rate Algorithms	14
12 Redukcja Wymiaru	15
13 Autoenkodery i encodery	16
14 Diffusion Models	17
15 Summary	18
References	19

Słowo wstępne

Notatki te powstają na potrzeby kursu o tym samym tytule, zaproponowanego w semestrze letnim roku akademickiego 2026/2027 w Instytucie Matematycznym Uniwersytetu Wrocławskiego.

Ich głównym celem jest zaznajomienie autora (a siłą rzeczy także czytelnika) z podstawowymi zasadami działania sieci neuronowych, które stanowią jeden z fundamentów dużych modeli językowych oraz modeli generatywnych. Nie chcemy traktować poszczególnych warstw sieci neuronowych jak czarnych skrzynek. Zamiast tego, poprzez analizę i implementację prostych, niskowymiarowych przykładów, będziemy starali się zrozumieć mechanizmy ich działania, a także ich mocne i słabe strony.

Lista źródeł, z których będę korzystał podczas przygotowywania tych notatek, ma charakter rozwojowy. Obecnie głównymi pozycjami są:

- *Mathematics of Neural Networks*, Bart Smets, <https://arxiv.org/pdf/2403.04807>
- *Alice's Adventures in a Differentiable Wonderland*, Simone Scardapane, <https://arxiv.org/pdf/2404.17625>
- *Neural Networks and Deep Learning*, Michael Nielsen, <http://neuralnetworksanddeeplearning.com/>

Notatki mają charakter roboczy i (jak wszystko we wstępnych fazach rozwoju) mogą zawierać błędy. Będę wdzięczny za zgłoszenie każdej usterki znalezionej w tekście.

Notatki są przygotowywane w Quarto, otwartym systemie do tworzenia publikacji naukowych i technicznych. Więcej informacji o Quarto można znaleźć na stronie <https://quarto.org/>.

1 Wstęp

W ciągu ostatnich kilkunastu lat uczenie maszynowe przeszło ogromny rozwój. Szczególną rolę odegrało w tym głębokie uczenie, oparte na sieciach neuronowych. Dzięki połączeniu prostych idei algorytmicznych, dużych zbiorów danych oraz rosnącej mocy obliczeniowej możliwe stało się rozwiązywanie zadań, które wcześniej były bardzo trudne, takich jak rozpoznawanie obrazów, przetwarzanie języka naturalnego, rozpoznawanie mowy czy analiza złożonych danych.

Sieci neuronowe są dziś jednym z podstawowych narzędzi sztucznej inteligencji. Wykorzystuje się je zarówno w widocznych zastosowaniach, takich jak duże modele językowe i generatory obrazów, jak i w systemach działających w tle: wyszukiwarkach, systemach rekomendacyjnych, analizie obrazów medycznych, projektowaniu leków czy technologiach autonomicznych.

Uczenie maszynowe polega na budowaniu modeli, które poprawiają swoje działanie na podstawie danych. Zamiast ręcznie projektować algorytm rozwiązujący dane zadanie, wybieramy ogólny model i uczymy go na przykładach. Gdy modelem tym jest sieć neuronowa z wieloma warstwami, mówimy o głębokim uczeniu.

Ważnym czynnikiem rozwoju głębokiego uczenia okazało się skalowanie. Zwiększanie rozmiaru modeli, ilości danych i mocy obliczeniowej często prowadzi do przewidywalnej poprawy wyników. Dzięki temu proste i ogólne metody, zastosowane w odpowiednio dużej skali, stały się niezwykle skuteczne.

Mimo imponujących sukcesów praktycznych nadal nie rozumiemy w pełni, dlaczego głębokie sieci neuronowe działają tak dobrze. Szczególnie interesujące jest to, że duże modele potrafią nie tylko zapamiętywać dane treningowe, ale także generalizować, czyli poprawnie działać na nowych przykładach.

Celem tych notatek jest wprowadzenie w podstawowe idee sieci neuronowych i głębokiego uczenia. Będziemy analizować zarówno intuicję, jak i formalny opis matematyczny modeli, aby zrozumieć, jak proste komponenty - warstwy, funkcje aktywacji, parametry, funkcje straty i algorytmy optymalizacji - pozwalają budować systemy zdolne do rozwiązywania złożonych problemów. Aby w pełni zrozumieć zasady działania sieci neuronowych skupimy się na niskowymiarowych przykładach.

2 Supervised Learning

3 Model neuronu i funkcja aktywacji

4 Płytkie uczenie

5 Stochastic Gradient Descent

6 Training

7 Głębokie sieci neuronowe

8 Initialization

9 Convolutional Neural Networks

10 Automatic Differentiation and Backpropagation

11 Adaptive Learning Rate Algorithms

12 Redukcja Wymiaru

PCA Krótko: po co redukujemy wymiar? SNE / t-SNE jako metoda wizualizacji UMAP jako metoda wizualizacji

13 Autoenkodery i encodery

14 Diffusion Models

15 Summary

In summary, this book has no content whatsoever.

References